Analiza recenzji i cech produktów z kategorii Video Games

Raport pierwszego etapu projektu

Przedmiot: Uczenie maszynowe

Valentyn Kovbasovskyi 71540
Daniil Khasanov 72295
Andrei Kudrytski 71527
Mykola Zhuchok 71899
Artur Reznychenko 71615

Spis treści

Podsumowanie 3

Zespół i podział odpowiedzialności 3

1 Cel projektu i dane źródłowe 4

Pytania badawcze 4

Pochodzenie i zakres 4

2 Zmienne i odtwarzalność podzbiorów 5

Trzy zakresy analiz 5

3 Jakość danych liczbowych i rozkłady 6

4 Zależności w danych liczbowych 7

5 Jakość tekstów i długość recenzji 8

6 Słownictwo i przygotowanie tekstu 9

7 Połączenie tekstu z cechami produktów 10

8 Stabilność wyników i odpowiedź na pytania 11

Ograniczenia 11

9 Odtworzenie wyników i źródła 12

Bibliografia i materiały projektu 12

Dalsze prace 12

Podsumowanie

Łączymy analizę tekstów recenzji z analizą liczbowych cech produktów w kategorii Video Games. Przygotowaliśmy dane, kontrolę jakości, analizę eksploracyjną oraz połączenie wyników na poziomie produktu. W analizie połączonej wykorzystano wszystkie 4 624 615 recenzji i uzyskano 137 249 produktów z prawidłowym dopasowaniem do metadanych.

Zależności między ceną, oceną i liczbą ocen są przeważnie słabe. Wyniki zależą od zakresu danych: znak korelacji długości recenzji z liczbą ocen zmienia się po ograniczeniu analizy do produktów z większą liczbą obserwowanych recenzji. Nie traktujemy tych zależności jako dowodu przyczynowości.

Zespół i podział odpowiedzialności

Uczestnik	Numer ID	Zakres odpowiedzialności
Valentyn Kovbasovskyi	71540	Lider; zebranie danych, GitHub, koordynacja, przegląd i integracja prac oraz wsparcie zespołu.
Daniil Khasanov	72295	Analiza tekstu, jakość recenzji, czyszczenie, długości tekstów i słownictwo.
Andrei Kudrytski	71527	Audyt danych liczbowych, rozkłady, ceny, oceny, braki i wartości odstające.
Mykola Zhuchok	71899	Agregacja recenzji, łączenie z produktami, wspólne wykresy i analiza zależności.
Artur Reznychenko	71615	Dokumentacja źródeł i podzbiorów, pytania badawcze, kontrola odtwarzalności i opracowanie raportu.

Zakres etapu obejmuje EDA i przygotowanie badań. Modele nadzorowane, K-means, LDA, Transformer oraz interfejs wyników należą do dalszych etapów.

Repozytorium projektu: github.com/Vamraf/ml-project

1 Cel projektu i dane źródłowe

Celem pierwszego etapu jest poznanie jakości oraz struktury rzeczywistych danych, wskazanie ograniczeń i sformułowanie pytań do kolejnych analiz. W raporcie odpowiadamy na pytania opisowe, które można ocenić bez trenowania modeli.

Pytania badawcze

P1 Czy cena produktu wiąże się z jego średnią oceną oraz liczbą ocen i czy zależności utrzymują się po zmianie sposobu traktowania obserwacji skrajnych?

P2 Jak różnią się długości i słownictwo recenzji o wysokich i niskich ocenach oraz jaki jest rozkład ocen?

P3 Czy średnia długość recenzji i udział ocen negatywnych wiążą się z cechami produktu oraz jak wyniki zależą od liczby recenzji przypadających na produkt?

Pochodzenie i zakres

Źródłem jest publiczny zbiór Amazon Reviews 2023 udostępniony przez McAuley Lab. Obejmuje on recenzje użytkowników i oddzielne metadane produktów [1, 2]. Wybraliśmy kategorię Video Games. Dwa zbiory wymagane w projekcie stanowią widok tekstowy recenzji i widok liczbowy produktów oraz recenzji, pochodzące z tej samej kategorii. Nie są to dwie niezależne kolekcje.

Plik przygotowany	Liczba wierszy	Zastosowanie
reviews_text.csv.gz	4 624 615	Tekst i tytuł recenzji, ocena, identyfikatory.
reviews_numeric.csv.gz	4 624 615	Liczbowe cechy recenzji oraz klucze łączenia.
products_numeric.csv	137 269	Cena, średnia ocena, liczba ocen i cechy metadanych produktu.

Pliki pobrano z repozytorium McAuley-Lab/Amazon-Reviews-2023 w Hugging Face. Manifest projektu zapisuje czas pobrania 23 października 2026, adresy źródeł, rozmiary plików, liczbę wierszy i SHA-256. Rewizja źródła: 2b6d039ed471f2ba5fd2acb718bf33b0a7e5598e [2, 3].

Pierwotne przygotowanie zachowało całą kategorię, bez losowania i usuwania wierszy. Oryginalne JSONL przechowujemy również w gzip bez zmiany zawartości po rozpakowaniu. Podzbiory i decyzje czyszczenia stosowane później opisujemy oddzielnie.

W dalszej części projektu planujemy porównywać modele tekstowe, liczbowe i podejście łączące cechy. Raport nie zawiera jeszcze wyników predykcji ani klasteryzacji.

2 Zmienne i odtwarzalność podzbiorów

Zmienna	Znaczenie i zasada interpretacji
parent_asin	Tekstowy klucz produktu; zachowujemy początkowe zera. Służy do łączenia recenzji i metadanych.
review_row	Numer oryginalnego wiersza recenzji, od zera; identyfikuje odpowiadające sobie widoki recenzji.
text oraz title	Tekst i tytuł recenzji. Oryginały pozostają dostępne niezależnie od czyszczenia.
rating	Ocena pojedynczej recenzji w skali 1–5.
price_usd	Cena z metadanych w USD; brak nie jest zerem. Cena zerowa jest zachowana w analizie podstawowej.
average_rating	Średnia ocena produktu podana w metadanych.
rating_number	Liczba ocen produktu z metadanych; nie musi równać się liczbie dostępnych wierszy recenzji.
observed_review_count	Liczba recenzji produktu faktycznie przetworzonych w danym uruchomieniu.
avg_review_chars	Średnia długość oryginalnego tekstu w znakach, wyłącznie wśród tekstów niepustych.
negative_share	Udział obserwowanych ocen 1 lub 2 wśród prawidłowych ocen danego produktu.

Trzy zakresy analiz

Analiza	Selekcja i czyszczenie
Dane liczbowe	Całe 137 269 produktów. Związki wymagające ceny: 61 972 kompletne rekordy. Dla logarytmicznej osi ceny wyłącznie 61 940 cen dodatnich.
Tekst	Pierwsze 500 000 recenzji z oryginalnego JSONL. Usunięto 1 594 duplikaty według user_id, asin, timestamp i text. Pozostało 498 406. Z nich wylosowano 100 000 wierszy z random_state=42.
Analiza połączona	Wszystkie 4 624 615 recenzji, przetwarzane blokami po 100 000. Zachowano wiersze źródłowe; powtarzający się tekst nie dowodzi tożsamości autora recenzji.

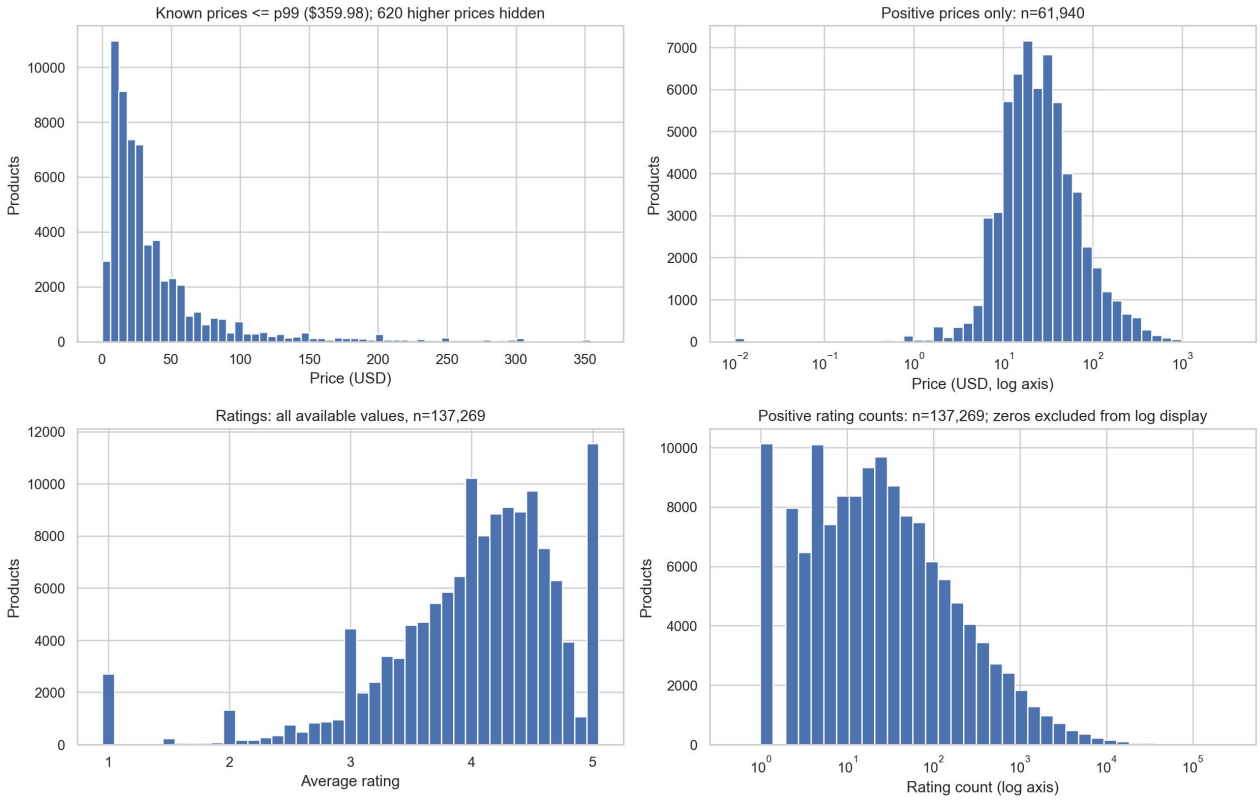
Podzbiór tekstowy jest losowany z prefiksu, a nie z pełnej kategorii. Jego rozkład ocen nie powinien być przedstawiany jako pełny rozkład kategorii. Skrypt zapisuje wybrane review_row, ziarno losowania, wersje bibliotek i podsumowanie uruchomienia. Różne zakresy nie są bezpośrednio wymiennymi próbami.

W analizie połączonej kontrolujemy kolejność review_row, format identyfikatorów, zakres ocen i zgodność SHA-256 z manifestem. Łączenie ma walidację jeden do jednego oraz osobny wskaźnik dopasowania klucza. Nie oceniamy dopasowania na podstawie samej obecności tytułu produktu.

3 Jakość danych liczbowych i rozkłady

Audyt pełnej tabeli produktów nie wykazał duplikatów parent_asin ani brakujących średnich ocen i liczby ocen. Brakuje dziewięciu tytułów produktów. Braki ceny dotyczą 75 297 produktów, czyli 54,85% tabeli. Istnieją również 32 ceny zerowe; bez dodatkowej wiedzy nie uznajemy ich automatycznie za błędy.

Miara	Cena USD	Średnia ocena	Liczba ocen
Liczba dostępnych wartości	61 972	137 269	137 269
Średnia	45,72	4,00	244,31
Mediana	24,95	4,10	21
Kwartyle 25% i 75%	13,00 i 45,99	3,60 i 4,50	5 i 87
Maksimum	3 499,99	5,00	278 574



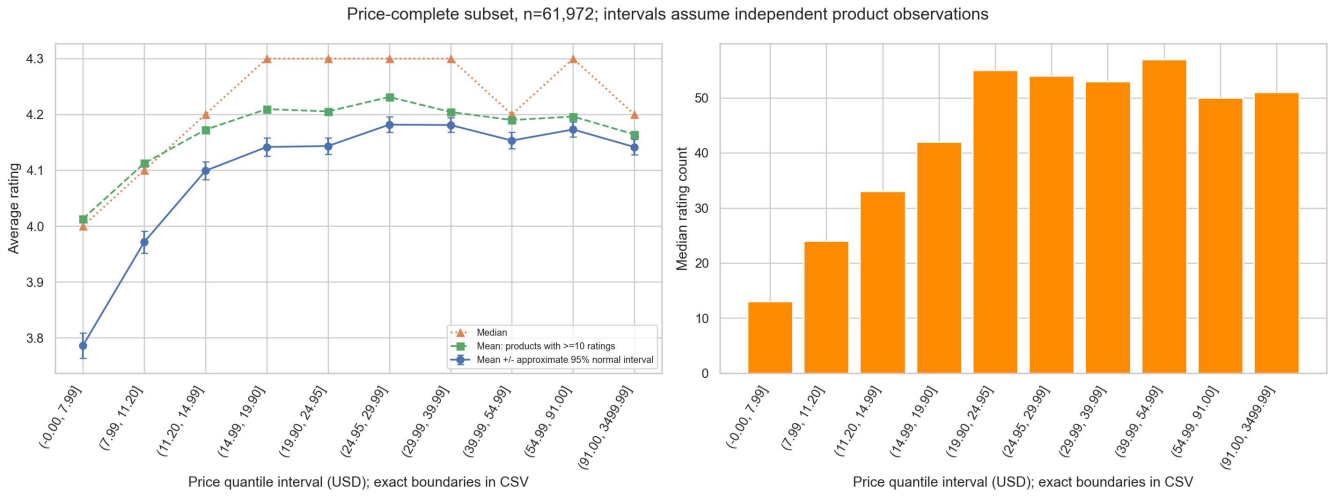
Rysunek 1. Rozkłady cen, średniej oceny i liczby ocen. Oceny i liczby ocen opisują pełną tabelę. Pierwszy histogram ceny ukrywa 620 obserwacji powyżej 99. percentyla, około 359,98 USD; wartości te pozostają w danych.

Cena i liczba ocen mają silnie prawostronne rozkłady: średnie przewyższają mediany, a niewiele produktów osiąga bardzo wysokie wartości. Skala logarytmiczna ułatwia ogląd rozkładu bez usuwania tych produktów. Wartości odstające oznaczamy regułą IQR na skali surowej i log1p, a ich wpływ badamy osobno.

4 Zależności w danych liczbowych

Na wspólnej próbie 61 972 produktów z kompletną ceną, oceną i liczbą ocen korelacje rangowe są dodatnie, lecz niewielkie. Zależności liniowe Pearsona są jeszcze słabsze. Poniższe współczynniki pochodzą z tych samych rekordów, dlatego można je porównywać.

Para cech	Pearson	Spearman
Cena i średnia ocena	0,0368	0,0931
Cena i liczba ocen	0,0149	0,1777
Średnia ocena i liczba ocen	0,0872	0,2790



Rysunek 2. Średnie i mediany ocen oraz mediany liczby ocen w grupach kwantylowych ceny. Przedziały ufności są przybliżone i zakładają niezależność obserwacji produktów.

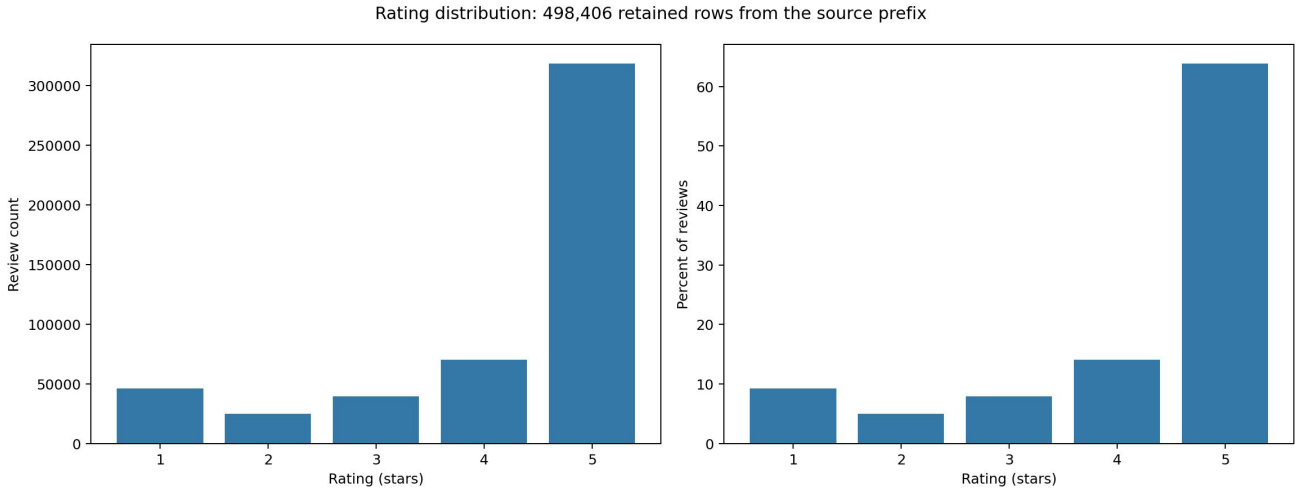
Produkty o znanej cenie różnią się od tych bez ceny: mediany średniej oceny wynoszą odpowiednio 4,2 i 4,0, a mediany liczby ocen 40 i 12. Test Manna–Whitneya wskazuje różnice rozkładów obserwowanych zmiennych; sam nie rozstrzyga, czy mechanizm braków jest MAR czy MNAR. Miara przewagi uwzględnia połowę udziału remisów.

Odfiltrowanie obserwacji poza granicami log-IQR daje korelację ceny z oceną 0,0970 wobec 0,0931 w analizie podstawowej; winsoryzacja daje 0,0931. Wynik jest podobny pod tymi wariantami. Po ograniczeniu do produktów z co najmniej 10 ocenami współczynnik spada do 0,0411. Dobór grupy produktów jest więc ważniejszy niż samo traktowanie wartości skrajnych.

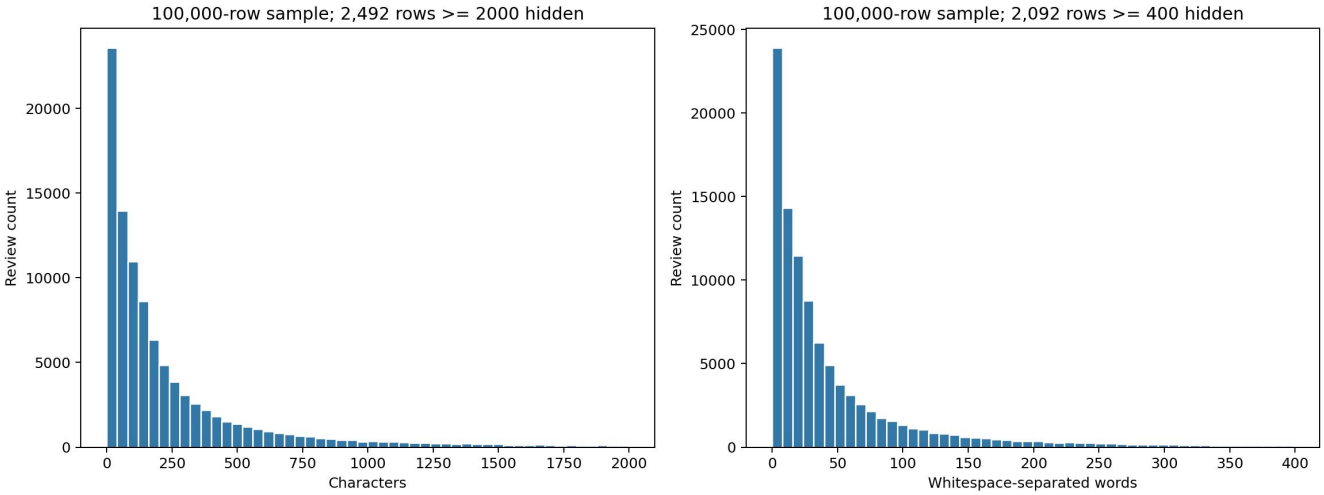
Wniosek dla P1: droższe produkty nie mają wyraźnie wyższych ocen w sensie silnej zależności. Niewielka dodatnia korelacja nie uzasadnia wniosku, że wzrost ceny powoduje wzrost oceny. Braki ceny ograniczają możliwość uogólnienia wyników na wszystkie produkty.

5 Jakość tekstów i długość recenzji

W źródłowym prefiksie 500 000 recenzji wykryto 144 teksty puste lub zawierające wyłącznie białe znaki. Po usunięciu 1 594 duplikatów według przyjętego klucza zachowano 498 406 recenzji. Oryginalne treści i identyfikatory pozostają zapisane; identyczne teksty przy innych tożsamościach nie są automatycznie usuwane.



Rysunek 3. Rozkład ocen w 498 406 zachowanych recenzjach prefiksu. Oceny pięciogwiazdkowe stanowią 63,89%, jednogwiazdkowe 9,22%. Nie jest to rozkład całej kategorii.



Rysunek 4. Długości oryginalnych tekstów w próbce 100 000 recenzji. Na wykresach ukryto odpowiednio 2 492 teksty o długości co najmniej 2 000 znaków i 2 092 teksty mające co najmniej 400 słów; nie usunięto ich z danych.

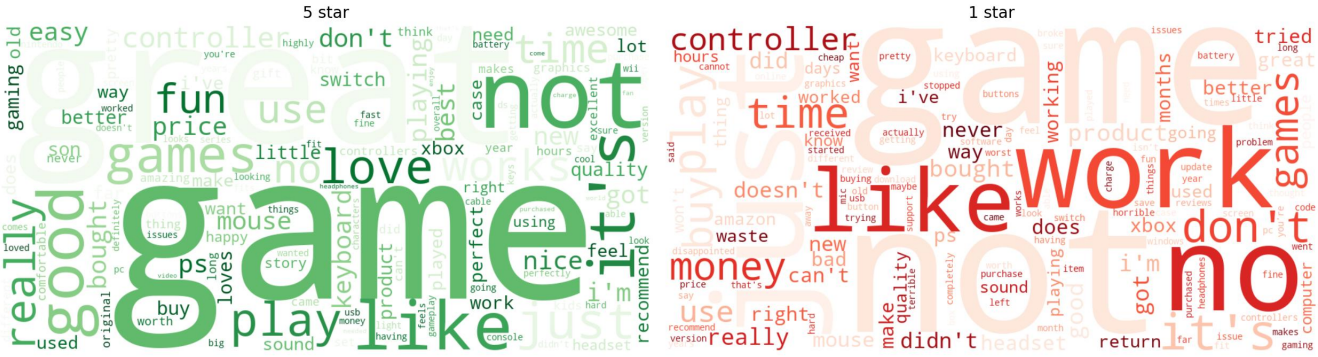
W próbce mediana długości wynosi 126 znaków i 24 słowa, a średnia 324,57 znaku i 59,74 słowa. Średnia większa od mediany wskazuje na długi prawy ogon. Po czyszczeniu 30 tekstów próbki jest pustych. Definicja liczby słów na tym wykresie to podział po białych znakach, odmienny od tokenizacji do analizy słownictwa.

6 Słownictwo i przygotowanie tekstu

Czyszczenie usuwa znaczniki HTML, dekoduje encje, normalizuje spacje i wielkość liter. Zachowuje cyfry, Unicode, interpunkcję, emoji i apostrofy. Oryginał jest przechowywany osobno. Tokenizacja słów stanowi oddzielny krok, a lista angielskich słów pomijanych została zmodyfikowana tak, aby zachować negację.

Porównujemy dokładnie recenzje z oceną 5 oraz dokładnie z oceną 1. W próbce jest ich odpowiednio 63 814 i 9 247. Częstość normalizujemy do 10 000 tokenów treści w każdej grupie; samo porównanie liczników faworyzowałoby liczniejszą klasę.

Słowo	Ocena 5 na 10 000 tokenów	Ocena 1 na 10 000 tokenów
game	242,04	234,62
not	106,57	241,36
great	159,38	28,22
like	94,59	77,40
work	27,76	80,75



Rysunek 5. Chmury słów dla ocen 5 i 1. Są ilustracją częstości, a nie modelem sentymentu. Przykładowe słowa wspólne, takie jak game, wynikają z tematyki kategorii.

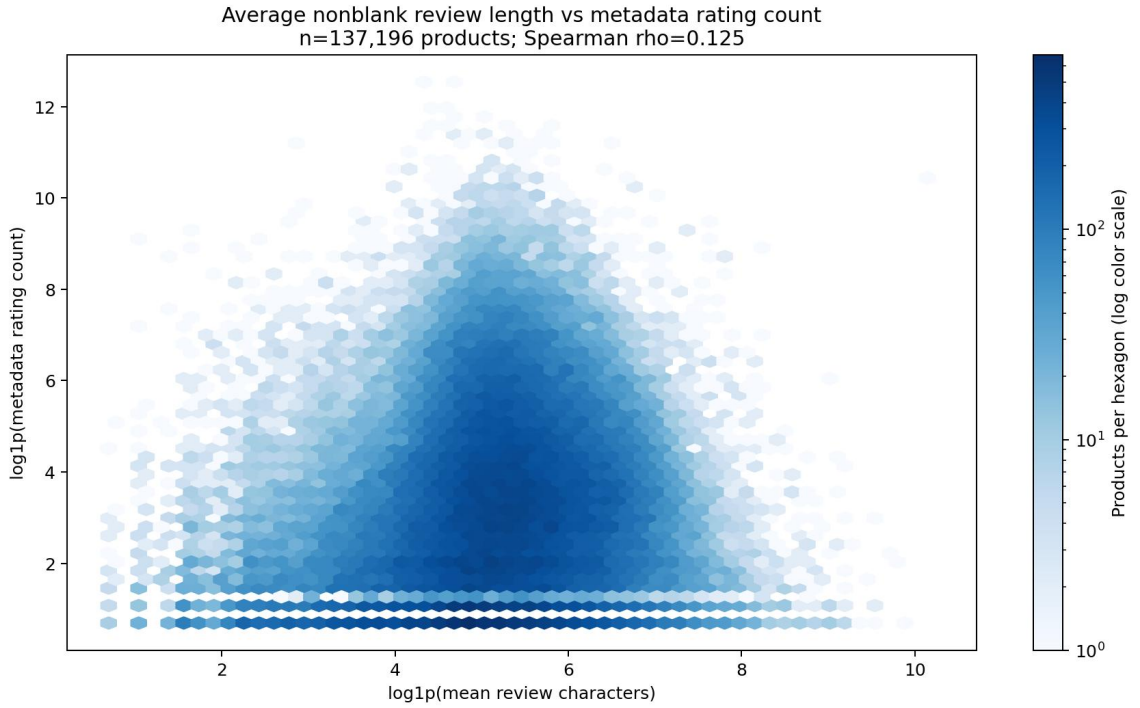
Negacja not występuje w grupie jednogwiazdkowej częściej po normalizacji. Częste work, controller czy money mogą wskazywać na temat działania produktu lub kosztu, ale pojedyncze słowo nie wystarcza do rozpoznania wydźwięku zdania. Również pozytywna recenzja może zawierać not. Zachowanie kontekstu jest ważne dla przyszłych modeli NLP.

Analiza obejmuje także bigramy. Pary wyrazów powstają z rzeczywiście sąsiadujących tokenów przed odrzuceniem par zawierających słowa pomijane; nie tworzymy sztucznych sąsiedztw po usunięciu słów. Wniosek dla P2: krótkie teksty dominują, klasy ocen są nierówne, a słownictwo różni się między skrajnymi ocenami, lecz wymaga analizy kontekstu.

7 Połączenie tekstu z cechami produktów

Przetworzyliśmy wszystkie 4 624 615 recenzji blokami po 100 000. Dla każdego parent_asin obliczono liczbę recenzji, średnią ocenę, średnie długości niepustych tekstów oraz udział ocen 1–2. Sumy i liczniki są łączone między blokami przed obliczeniem średnich, dzięki czemu liczebność bloków nie zmienia wag obserwacji.

Kontrola połączenia	Wynik
Produkty obserwowane w recenzjach	137 249
Prawidłowo dopasowane klucze	137 249; brak niedopasowanych kluczy
Produkty metadanych bez recenzji w pliku	20
Puste tytuły wśród dopasowanych produktów	9; nie oznaczają braku dopasowania
Puste teksty w pełnym zbiorze	3 618; wyłączone tylko ze średnich długości



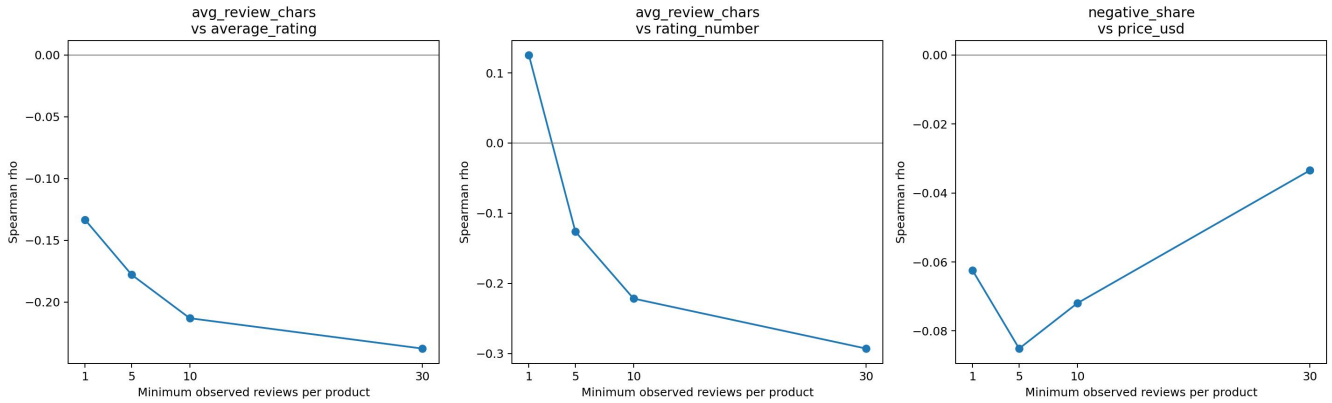
Rysunek 6. Średnia długość niepustych recenzji a liczba ocen z metadanych. Wykres obejmuje 137 196 produktów i wykorzystuje osie log1p oraz heksagonalne zliczanie zagęszczenia.

Liczba obserwowanych recenzji nie jest utożsamiana z rating_number. Miary mogą różnić się z powodu zakresu plików i momentu zebrania danych. Produkty mają jednakową wagę w korelacjach, niezależnie od liczby ich recenzji. Braki ceny eliminują produkt tylko z analiz, które wymagają ceny.

8 Stabilność wyników i odpowiedź na pytania

Minimalna liczba recenzji	Długość i ocena	Długość i liczba ocen	Negatywne i cena
1	−0,1334	+0,1254	−0,0625
5	−0,1779	−0,1263	−0,0851
10	−0,2131	−0,2218	−0,0720
30	−0,2377	−0,2930	−0,0335

Tabela przedstawia korelacje Spearmana. Liczebność jest odrębna dla każdej pary: przy progu 1 długość i liczba ocen wykorzystują 137 196 produktów, a udział negatywnych ocen i cena 61 965. Przy progu 30 są to odpowiednio 20 518 i 13 461 produktów.



Rysunek 7. Zmiana współczynników po zwiększeniu minimalnej liczby obserwowanych recenzji. Progi zmieniają skład analizowanej grupy; nie są kolejnymi pomiarami tego samego zbioru.

Odpowiedź na P3: w pełnym zestawie grup produktowych długość tekstu i liczba ocen mają dodatnią korelację 0,1254. Po ograniczeniu do co najmniej pięciu recenzji znak zmienia się na ujemny, a dla co najmniej 30 wynosi −0,2930. Nie ma więc podstaw do bezwarunkowego twierdzenia, że popularniejsze produkty otrzymują dłuższe lub krótsze recenzje. Zależność zależy od doboru grupy.

Długość tekstu ma słabą ujemną zależność ze średnią oceną metadanych, a udział ocen negatywnych bardzo słabą ujemną zależność z ceną. Obserwacje nie dowodzą przyczyn. W pełnym zbiorze 37 839 produktów ma jedną recenzję, a 74 069 mniej niż pięć, co uzasadnia kontrolę stabilności średnich i udziałów.

Ograniczenia

Braki ponad połowy cen, prefiksowy dobór danych tekstowych i mała liczba recenzji wielu produktów ograniczają uogólnianie. Korelacja udziału ocen negatywnych ze średnią oceną recenzji częściowo wynika z ich wspólnej definicji. Małe wartości p przy dużej próbie nie oznaczają silnego efektu; zapis p=0 w pliku oznacza ograniczenie precyzji obliczeń.

9 Odtworzenie wyników i źródła

Kod, oryginalne dane, instrukcje i 15 opublikowanych grafik znajdują się w publicznym repozytorium [3]. Raport odnosi się do analiz dostępnych w stanie repozytorium 5862640. Wymagany jest Python 3.11 lub nowszy oraz Git LFS. Polecenia wykonujemy w katalogu repozytorium:

```
git lfs install
git clone https://github.com/Vamraf/ml-project.git
cd ml-project
git lfs pull
python -m pip install -r notebooks/eda/requirements-numeric-eda.txt
python -m pip install -r notebooks/eda/requirements-text-eda.txt
python -m pip install -r notebooks/eda/requirements-combined-eda.txt
python notebooks/eda/01_audit.py
python notebooks/eda/02_analysis.py
python notebooks/eda/03_text_eda.py
python notebooks/eda/04_combined_eda.py
```

Skrypty ustalają ścieżki na podstawie położenia pliku. Dane skompresowane są czytane bez ręcznego rozpakowywania. Tabele, wyniki kontroli i opisy trafiają do reports/stage-1, a grafiki do reports/figures, w podkatalogach numeric_eda, text_eda i combined_eda. Dla tekstu wymagany jest oryginalny JSONL, jeśli chcemy odtworzyć usuwanie duplikatów według user_id i timestamp; klon zawiera go w gzip.

Bibliografia i materiały projektu

[1] McAuley Lab. Amazon Reviews 2023. Opis zbioru i kategorii. Dostęp 30.10.2026. Strona źródłowa

[2] McAuley-Lab/Amazon-Reviews-2023, Hugging Face. Rewizja 2b6d039ed471f2ba5fd2acb718bf33b0a7e5598e. Repozytorium danych

[3] Zespół ml-project. Kod analiz, dane i wyniki. GitHub oraz instrukcje odtwarzania

[4] Manifest pochodzenia danych i kontrolne sumy SHA-256. download_manifest.json

[5] Alex Zaremba. Uczenie maszynowe Projekt 1. Dokument wymagań ML_proj_1.pdf, przechowywany w docs/requirements/project-requirements.pdf.

[6] Wyniki uruchomień 01_audit.py, 02_analysis.py, 03_text_eda.py i 04_combined_eda.py: tabele jakości, korelacji, statystyk i wrażliwości; instrukcje poszczególnych analiz w notebooks/eda.

Dalsze prace

W kolejnych etapach planujemy modele nadzorowane, K-means, LDA, Transformer i interfejs wyników. Należy zapobiegać przeciekowi informacji przy podziale danych i dopasowaniu przetwarzania. Nie przedstawiamy tych eksperymentów jako już wykonanych.

Wyniki liczbowe pochodzą z uruchomionych skryptów; nie traktujemy korelacji jako dowodu przyczynowości.